

Modélisation des données Spatiales

Pâquarse Delvich Van Mahouvi, Ronan Gonnet, Romain Ponsort

2022-12-12

clear data & close graphs

Définition du répertoire

```
setwd("~/Cours M2 MAS/Modele de donnees spatiales/Projet Delvich-Ronan-Romain")
```

Les packages

```
library(magrittr)
```

Warning: le package 'magrittr' a été compilé avec la version R 4.2.2

```
library(RColorBrewer)
```

```
library(hrbrthemes)
```

NOTE: Either Arial Narrow or Roboto Condensed fonts are required to use these themes.

Please use `hrbrthemes::import_roboto_condensed()` to install Roboto Condensed and

if Arial Narrow is not on your system, please see <https://bit.ly/arialnarrow>

```
library(rgdal)
```

Le chargement a nécessité le package : sp

Please note that `rgdal` will be retired by the end of 2023,
plan transition to `sf/stars/terra` functions using GDAL and PROJ
at your earliest convenience.

rgdal: version: 1.5-32, (SVN revision 1176)

Geospatial Data Abstraction Library extensions to R successfully loaded

Loaded GDAL runtime: GDAL 3.4.3, released 2022/04/22

Path to GDAL shared files: C:/Users/Paqua/AppData/Local/R/win-library/4.2/rgdal/gdal

GDAL binary built with GEOS: TRUE

Loaded PROJ runtime: Rel. 7.2.1, January 1st, 2021, [PJ_VERSION: 721]

Path to PROJ shared files: C:/Users/Paqua/AppData/Local/R/win-library/4.2/rgdal/proj

PROJ CDN enabled: FALSE

Linking to sp version:1.5-0

To mute warnings of possible GDAL/OSR `exportToProj4()` degradation,

use `options("rgdal_show_exportToProj4_warnings"="none")` before loading sp or rgdal.

```
library(dplyr)
```

Attachement du package : 'dplyr'

Les objets suivants sont masqués depuis 'package:stats':

`filter`, `lag`

Les objets suivants sont masqués depuis 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

Contents

clear data & close graphs	2
Définition du répertoire	2
Les packages	2
Introduction	4
1 Ouverture de la base	4
2 Visualisation et pré-traitement des données	4
2.1 Visualisation des données	4
2.2 Statistique descriptive Univariée	5
2.2.1 BoxPlot du taux de cambriolage pour 1000 habitants	5
2.2.2 Cartographie du taux de cambriolage pour 1000 habitants	6
2.3 Statistiques bivariée	7
2.3.1 Matrice de corrélation des variables explicatives	7
2.3.2 Choix des variables explicatives pour la suite	8
3 Définition des matrices de distance	8
3.1 Définition de la matrice des poids : Relations basées sur la connectivité :	8
3.1.1 Définition de la matrice des poids - Connectivité : Alternative Contiguity matrix	9
3.1.2 Définition de la matrice des poids - Connectivité : Alternative Closest neighbors	10
3.2 Définition de la matrice des poids - Euclidean distance	11
3.3 Comparaison des statistiques pour observer l'influence du choix de la matrice de poids sur les résultats	11
4 Analyse de l'autocorrélation Spatiale	12
4.1 Analyse de l'autocorrélation Spatiale Globale : Indice de Moran	12
4.1.1 Matrice de contiguïté	12
4.1.2 Matrice des plus proches voisins	15
4.1.3 L'inverse de la distance	18
5 Estimation des modèles via la stratégie de test Top-Down	21
5.1 Estimation des modèles	21
5.1.1 Modèle OLS	22
5.1.2 Modèle SLX	22
5.1.3 Modèle SAR	22
5.1.4 Modèle SEM	22
5.1.5 Modèle SDM	22
5.2 Strategy of test Top Down approach LeSage & Pace (2009)	22
5.3 Visualisation du modèle	24
5.4 Interprétation du modèle	24
5.5 Test sur le modèle	24
5.5.1 Test de Moran	25
5.6 Test avec une matrice des cinq plus proche voisins	25
Conclusion	26

Introduction

Le cambriolage est un phénomène inquiétant en France. En 2018, 1,7% des ménages ont déclaré avoir été victimes d'un cambriolage de leur résidence principale (INSEE). Pour 55% d'entre eux le cambriolage n'a pas abouti et s'est arrêté au stade de la tentative.

La moitié des victimes de cambriolage déposent plainte à la police ou à la gendarmerie. En 2019, les services de police et de gendarmerie ont enregistré 217 500 cambriolages et tentatives de cambriolage de résidence principale.

On a décidé d'appuyer nos analyses sur des données départementales de l'année 2019. L'objectif sera donc d'apprécier l'influence du taux de cambriolage des départements voisins sur un département mais aussi l'influence d'autres facteurs comme le taux de chômage sur ce fléau.

1 Ouverture de la base

L'intégralité des données utilisées proviennent de l'INSEE. Pour plusieurs variables, le nom de la variable a été modifié pour permettre une utilisation plus simple lors de leurs traitements.

```
base <- openxlsx::read.xlsx(xlsxFile = "bdd_projet.xlsx", rowNames = TRUE)
```

2 Visualisation et pré-traitement des données

2.1 Visualisation des données

```
stargazer::stargazer(base, type = "text", title = "vue des données")
```

vue des données

Statistic	N	Mean	St. Dev.	Min	Max
Cambriolage	96	5.835	2.302	1.900	12.100
Taux_chomage_2019	96	8.125	1.588	4.925	13.625
Domicile_au_moins_une_voiture	96	84.842	7.183	33.500	91.800
Pop_active	96	44.936	2.297	39.893	55.033
Ratio_homme_femme	96	0.942	0.019	0.880	0.990
Part_Maison	96	63.217	17.420	0.800	86.500
Part_Appartement	96	35.861	17.255	12.900	96.900
Policier_Gendarme	96	3.223	1.262	1.600	11.700
Personne_Seule	96	369.000	31.708	294	518

Pour une meilleure compréhension de nos variables, on observe également la nature des variables potentielles.

```
str(base)
```

```
'data.frame':  96 obs. of  10 variables:
 $ Code           : chr  "01" "02" "03" "04" ...
 $ Cambriolage    : num  8.2 7 5 5 2.4 8 4.6 4.6 4.4 6.8 ...
 $ Taux_chomage_2019 : num  6.05 11.65 8.9 9.75 7.97 ...
 $ Domicile_au_moins_une_voiture: num  91 83.1 85 87.9 88.4 77.7 90 83 87.7 82.7 ...
 $ Pop_active     : num  47.9 44.5 42.6 42.7 45.2 ...
 $ Ratio_homme_femme : num  0.97 0.95 0.92 0.96 0.96 0.9 0.95 0.95 0.97 0.94 ...
 $ Part_Maison    : num  63.2 75.5 71.7 60.8 43.1 23.7 74.7 71.1 79.6 65.6 ...
 $ Part_Appartement : num  36 23.7 27.6 38 56.2 75.6 24.5 28.2 19.1 33.4 ...
```

```
$ Policier_Gendarme      : num  2 3 4.1 3.9 4.5 3.3 2.6 3.5 3.7 3.2 ...
$ Personne_Seule         : num  322 338 413 389 389 402 356 352 388 386 ...
```

- Verification des valeur manquantes

```
sum(is.na(base))
```

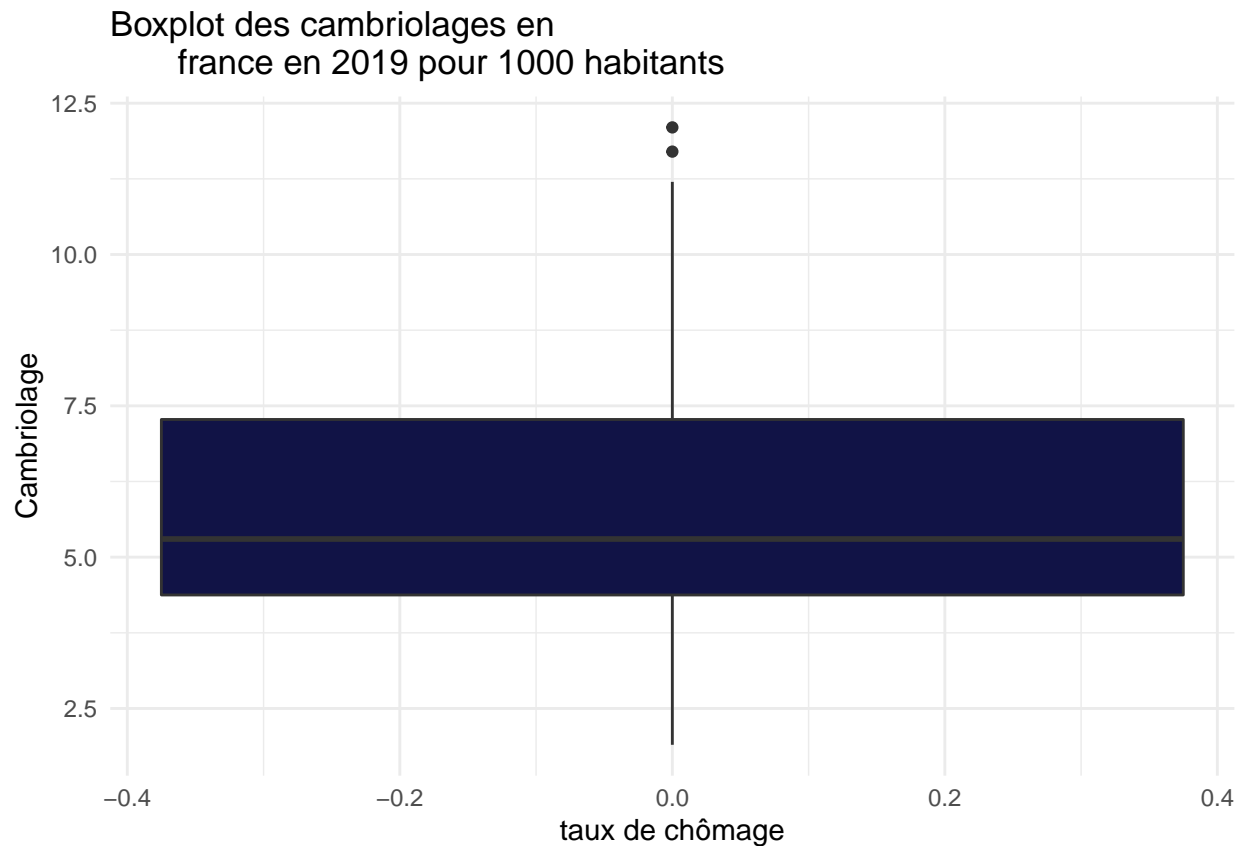
```
[1] 0
```

On peut donc remarquer l'absence de valeurs manquantes dans notre base de données.

2.2 Statistique descriptive Univariée

2.2.1 BoxPlot du taux de cambriolage pour 1000 habitants

```
options(width = 200)
library(ggplot2)
ggplot(base) +
  aes(x = Cambriolage) +
  geom_boxplot(fill = "#111346", position = "dodge2", orientation = "y") +
  labs(y = "taux de chômage", title = "Boxplot des cambriolages en
  france en 2019 pour 1000 habitants") +
  theme_minimal() +
  theme(plot.subtitle = element_text(face = "italic")) +
  coord_flip()
```



2.2.2 Cartographie du taux de cambriolage pour 1000 habitants

```
# lecture du shapefile
```

```
carte <- raster::getData('GADM', country='FRA', level=2)
```

Warning in raster::getData("GADM", country = "FRA", level = 2): getData will be removed in a future version. Please use the geodata package instead

```
# fusion des tables et suppression des variables inutiles
```

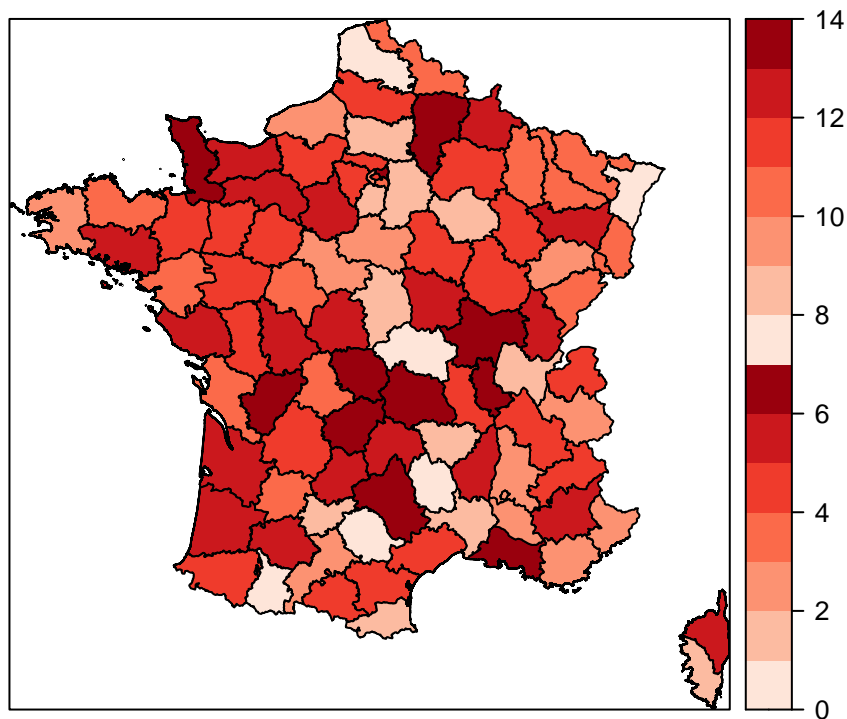
```
carte@data <- merge(carte@data, base, by.x = "CC_2", by.y = "Code")
```

```
# fusion des tables et suppression des variables inutiles
```

```
carte@data <- carte@data%>%
```

```
  dplyr::select(c("CC_2", "Cambriolage", "NAME_1", "NAME_2", "Domicile_au_moins_une_voiture",  
                  "Pop_active", "Ratio_homme_femme", "Taux_chomage_2019",  
                  "Ratio_homme_femme", "Part_Maison", "Part_Appartement",  
                  "Policier_Gendarme", "Personne_Seule"  
                ))
```

```
sp::spplot(carte, "Cambriolage", sub = "Taux de cambriolage en france pour 1000 habitants  
en 2019",  
            at = seq(0, 14, 1), col.regions = brewer.pal(7, "Reds"),  
            border = "white")
```



**Taux de cambriolage en france pour 1000 habitants
en 2019**

2.3 Statistiques bivariée

2.3.1 Matrice de corrélation des variables explicatives

```
cor.mtest <- function(mat, ...) {
  mat <- as.matrix(mat)
  n <- ncol(mat)
  p.mat<- matrix(NA, n, n)
  diag(p.mat) <- 0
  for (i in 1:(n - 1)) {
    for (j in (i + 1):n) {
      tmp <- cor.test(mat[, i], mat[, j], ...)
      p.mat[i, j] <- p.mat[j, i] <- tmp$p.value
    }
  }
  colnames(p.mat) <- rownames(p.mat) <- colnames(mat)
  p.mat
}

# Matrice de p-value de la corrélation
p.mat <- cor.mtest(base[,c(-1, -2)])

# Affichage pour sortir
stargazer::stargazer(p.mat, type = "text", title = "Matrice de corrélation")
```


Matrice de corrélation

	Taux_chomage_2019	Domicile_au_moins_une_voiture	Pop_active	Ratio_homme_fer
Taux_chomage_2019	0	0.416	0.00004	0.007
Domicile_au_moins_une_voiture	0.416	0	0	0.00002
Pop_active	0.00004	0	0	0.310
Ratio_homme_femme	0.007	0.00002	0.310	0
Part_Maison	0.934	0	0	0.005
Part_Appartement	0.943	0	0	0.005
Policier_Gendarme	0.897	0	0.007	0.004
Personne_Seule	0.470	0.00004	0.663	0.00000

```
M <- cor(base[,c(-1, -2)])
my_colors <- brewer.pal(5, "Spectral")
my_colors <- colorRampPalette(my_colors)(100)
ord <- order(M[1, ])
M_ord <- M[ord, ord]
#ellipse::plotcorr(M_ord, col=my_colors[M_ord*50+50], mar=c(1,1,1,1))

col <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD", "#4477AA"))
corrplot::corrplot(M, method="color", col=col(200),
  type="upper", order="hclust",
  addCoef.col = "black", # Ajout du coefficient de corrélation
  tl.col="black", tl.srt=45, #Rotation des etiquettes de textes
  # Combiner avec le niveau de significativité
  p.mat = p.mat, sig.level = 0.05, insig = "blank",
  # Cacher les coefficients de corrélation sur la diagonale
```

```
)
diag=FALSE, number.cex = 0.5
```



```
rm(my_colors, ord, p.mat, col, cor.mtest, M_ord)
```

2.3.2 Choix des variables explicatives pour la suite

Le choix des variables explicatives pour la suite de notre variable s'est faite en nous basant sur la littérature (notamment les autres études faites sur la criminalité en France), combiné à l'importance des variables pour un modèle de randomForest. L'objectif n'étant de tester ou d'apprendre des techniques de sélection de variable, les résultats de variable importance du randomForest n'est pas présenté dans le présent document.

```
carte@data <- carte@data%>%
  dplyr::select(c("CC_2", "Cambriolage", "NAME_1", "NAME_2", "Taux_chomage_2019", "Part_Maison",
    "Policier_Gendarme", "Personne_Seule"))
```

3 Définition des matrices de distance

3.1 Définition de la matrice des poids : Relations basées sur la connectivité :

On récupère les coordonnées spatiales. Pour les polygones spatiaux, il renvoie les centroïdes des zones d'emploi.

```
coord <- coordinates(carte)
```


3.1.1 Définition de la matrice des poids - Connectivité : Alternative Contiguity matrix

```
library(spdep)
```

Le chargement a nécessité le package : spData

To access larger datasets in this package, install the spDataLarge package with: ``install.packages('spDataLarge')`

Le chargement a nécessité le package : sf

Linking to GEOS 3.9.1, GDAL 3.4.3, PROJ 7.2.1; sf_use_s2() is TRUE

```
carte.nb <- poly2nb(carte)
summary(carte.nb)
```

Neighbour list object:

Number of regions: 96

Number of nonzero links: 478

Percentage nonzero weights: 5.186632

Average number of links: 4.979167

Link number distribution:

```
 1  2  3  4  5  6  7  8 10
```

```
 2  6 10 16 19 30 11  1  1
```

2 least connected regions:


67 68 with 1 link

1 most connected region:

87 with 10 links

On remarque que les centroïdes ont en moyenne 4.979167 liens. Affichage des liens :

```
plot(carte)
plot(carte.nb, col="red",cex=0.1,coord,add=TRUE)
```



```
cont.w <- nb2listw(carte.nb,style="W")
cont.w
```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 96

Number of nonzero links: 478

Percentage nonzero weights: 5.186632

Average number of links: 4.979167

Weights style: W

Weights constants summary:

	n	nn	S0	S1	S2
W	96	9216	96	44.07222	391.414

La fonction `nb2listw` complète la liste de voisins avec des poids spatiaux pour le schéma de codage choisi. La fonction d'aide `can.be.simmed` vérifie si un objet de poids spatial est similaire à symétrique et peut être transformé de cette façon pour produire des valeurs propres réelles ou pour la décomposition de Cholesky. On regarde que les villes ont en moyenne 5 voisins.

3.1.2 Définition de la matrice des poids - Connectivité : Alternative Closest neighbors

```
### Definition of the 5 closest neighbors
cartePPV5.knn<-knearneigh(coord,k=5)
cartePPV5.nb<- knn2nb(cartePPV5.knn)
# Matrice de poids
PPV5.w<-nb2listw(cartePPV5.nb,style="W")
```

3.2 Définition de la matrice des poids - Euclidean distance

Relation basée sur l'inverse de la distance. Prendre l'inverse de la distance est la manière la plus naturelle de modéliser une influence décroissante avec la distance.

Ici, nous travaillons avec des départements (96 au total), donc les distances entre départements sont plus faibles que les distances entre communes (vu en cours). Malgré ces petites valeurs, il faudra également diviser par 1000 pour avoir les distances en km et ainsi opérer un choix pour lambda en nous basant sur le graphique de la page 47 du chapitre 1.

```
distance<- fields::rdist(coord,coord)/1000 #for a distance in km  
# La règle des distances notifie que la diagonale doit être égale à 0  
diag(distance)<-0
```

-> Choix du seuil et Choix de lambda

Pour le choix du seuil de dichotomisation, on a choisi d'évaluer sur la matrice des distances, la distance moyenne qui sépare les départements entre eux. Pour avoir une répartition pas trop déséquilibrée, on a donc pris la médiane des moyennes. Par exemple, pour le département d'Ille-et-Vilaine, on a pris la distance moyenne entre ledit département et tous les autres. Ceci répété pour tous les départements, ensuite on a pris la médiane des moyennes.

Par ailleurs, pour le choix de lambda, on a opté pour $\lambda = 1$. Ainsi, on accorde plus de poids aux variables qui sont spatialement plus proches (plus petite distance) afin de laisser moins de poids aux variables plus éloignées.

```
# Choix du seuil  
seuil <- median(apply(distance, MARGIN = 2, FUN = mean))  
  
# Dichotomisation  
distance[distance>= seuil ]<-0  
  
#gamma =1  
dist1<- ifelse(distance>0, 1.0/distance,0)  
  
# Matrice de poids  
dist.w1<-mat2listw(dist1, row.names = NULL, style="W")  
rm(seuil, distance, dist1)
```

Ainsi, nous avons les 3 matrices de poids :


- Matrice de contiguïté (connectivity) : cont.w
- Critère des plus proche voisins (connectivity) : PPV5.w
- Inverse de la distance ($\lambda = 1$) : dist.w1

3.3 Comparaison des statistiques pour observer l'influence du choix de la matrice de poids sur les résultats

On représente la boîte à moustache du cambriolage en plus de celui de cambriolage par différente matrice afin d'avoir un aperçu visuel de l'effet de la matrice de poids sur le cambriolage

```
cambriolage <- cbind(base$Cambriolage)  
cont.w_cambriolage <- lag.listw(cont.w, cambriolage)  
ppv5.w_cambriolage <- lag.listw(PPV5.w, cambriolage)  
dist.w1_cambriolage <- lag.listw(dist.w1, cambriolage)  
par(mfrow = c(2,2))  
graphics::boxplot.matrix(cambriolage)  
graphics::boxplot.matrix(cont.w_cambriolage)
```

```
graphics::boxplot.matrix(ppv5.w_cambriolage)
graphics::boxplot.matrix(dist.w1_cambriolage)
```



```
rm(cambriolage, cont.w_cambriolage, ppv5.w_cambriolage, dist.w1_cambriolage)
```

4 Analyse de l'autocorrélation Spatiale

4.1 Analyse de l'autocorrélation Spatiale Globale : Indice de Moran

Les indices d'autocorrélation spatiale sont utilisés pour caractériser la corrélation entre les mesures qui sont géographiquement similaires à un phénomène mesuré. Si WY est le vecteur des moyennes de la variable Y (où W est la matrice des poids spatiaux) au voisinage de chaque unité spatiale, les indices d'autocorrélation spatiale se présentent comme suit : (confère cours p.9 chapter 2).

- H_0 : no spatial autocorrelation

Pour éviter les problèmes liés à la dimension, nous allons centrer la variable cible.

```
carte$Cambriolage_centered <- carte$Cambriolage - mean(carte$Cambriolage)
```

4.1.1 Matrice de contiguïté

```
MoranTest_Cont_W <- moran.test(carte$Cambriolage_centered, cont.w, randomisation = FALSE,
                               alternative = "greater")
```

```
MoranTest_Cont_W
```

4.1.1.1 Autocorrelation Spatiale Globale

Moran I test under normality

```
data:  carte$Cambriolage_centered
weights: cont.w
```


Moran I statistic standard deviate = 1.5276, p-value = 0.06331

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.092570053	-0.010526316	0.004554958

```
moran.plot(x = carte$Cambriolage_centered, listw = cont.w, xlab = "Taux de cambriolage 2019
centrée", ylab = "Spatial lag cambriolage 2019 centrée", sub = "Cambriolage et
Matrice de contiguïté_cambriolage",
labels = as.character(row.names(carte)))
```



- Interprétation :

Moran I statistic standard deviate = 1.5276 > 0 ==> Possible Positive spatial autocorrelation p-value = 0.06331 > 0.05 ==> On ne rejette pas H₀ (No Spatial Correlation)

```
locm_w <- localmoran(carte$Cambriolage_centered, cont.w)
head(locm_w)
```

4.1.1.2 Autocorrelation Spatiale locale (LISA)

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
1	-0.30150224	-0.011221677	0.16808882	-0.7080249	0.4789298
5	0.13646569	-0.002722010	0.04112331	0.6863677	0.4924813
6	-0.07627672	-0.001400731	0.01795866	-0.5587346	0.5763429
7	-0.14037003	-0.001400731	0.02118986	-0.9546733	0.3397429
8	-0.95932469	-0.023686852	0.42512082	-1.4349990	0.1512874
9	-0.06414222	-0.009403665	0.17124178	-0.1322783	0.8947642

```
summary(locm_w)
```

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
Min.	:-2.16413	Min. :-7.876e-02	Min. :0.000038	Min. :-2.7974	Min. :0.005152
1st Qu.:	-0.12911	1st Qu.:-1.346e-02	1st Qu.:0.025591	1st Qu.:-0.5891	1st Qu.:0.199421
Median :	0.03409	Median :-4.433e-03	Median :0.094415	Median : 0.1971	Median :0.415789
Mean :	0.09257	Mean :-1.053e-02	Mean :0.281479	Mean : 0.1448	Mean :0.430990
3rd Qu.:	0.21659	3rd Qu.:-1.500e-03	3rd Qu.:0.295164	3rd Qu.: 0.8613	3rd Qu.:0.609910
Max. :	3.30213	Max. :-2.520e-06	Max. :6.965858	Max. : 2.7550	Max. :0.978165

```
carte$ContW_cambriolage <- lag.listw(cont.w, carte$Cambriolage_centered)
#create a new variable for quadrants
carte$quad_sig <- NA

##HH
carte@data[(carte$Cambriolage_centered >= 0 & carte$ContW_cambriolage >= 0) &
  (locm_w[,5] <= 0.05), "quad_sig"] <- 1.0

##LL
carte@data[(carte$Cambriolage_centered <= 0 & carte$ContW_cambriolage <= 0) &
  (locm_w[,5] <= 0.05), "quad_sig"] <- 2.0

##HL
carte@data[(carte$Cambriolage_centered >= 0 & carte$ContW_cambriolage <= 0) &
  (locm_w[,5] <= 0.05), "quad_sig"] <- 3.0

##LH
carte@data[(carte$Cambriolage_centered <= 0 & carte$ContW_cambriolage >= 0) &
  (locm_w[,5] <= 0.05), "quad_sig"] <- 4.0

#pas significatifs
carte@data[(locm_w[,5] > 0.05), "quad_sig"] <- 5.0

table(carte$quad_sig)
```

4.1.1.3 Cartes des LISAs prenant en compte la significativité

```
1 3 4 5
3 2 3 88

labels <- c("high-High", "low-Low", "High-Low", "Low-High", "Not Signif.")

# need for the map
breaks <- seq(1, 5, 1)
```


```

carte$np <- findInterval(carte$squad_sig, breaks)

col.map <- c("red", "blue", "lightpink", "skyblue2", "yellow")
plot(carte, col = col.map[carte$np])
mtext("Local Moran's I Significatif or Not", cex = 1.5, side = 3, line = 1)
legend("topleft", legend = labels, col=c("red", "blue", "lightpink", "skyblue2", "yellow"),
      lty=1:2, cex=0.8)

```

Local Moran's I Significatif or Not



4.1.2 Matrice des plus proches voisins

```

MoranTest_ppv5.w <- moran.test(carte$Cambriolage_centered, PPV5.w, randomisation = FALSE,
                              alternative = "greater")

```

```

MoranTest_ppv5.w

```

4.1.2.1 Indice de Moran

Moran I test under normality

```

data: carte$Cambriolage_centered
weights: PPV5.w

```

```

Moran I statistic standard deviate = 2.2755, p-value = 0.01144
alternative hypothesis: greater

```


sample estimates:

Moran I statistic	Expectation	Variance
0.12326334	-0.01052632	0.00345693

```

moran.plot(x = carte$Cambriolage_centered, listw = PPV5.w, xlab = "Taux de cambriolage 2019
centrée", ylab = "Spatial lag cambriolage 2019 centrée", sub = "Cambriolage et
Matrice des cinq (05) plus proches voisins_cambriolage",
labels = as.character(row.names(carte)))

```



- Interprétation :

Moran I statistic standard deviate = 2.2755 > 0 ==> Positive spatial autocorrelation p-value = 0.01144 < 0.05 ==> On rejette H₀ (Spatial Autocorrelation)

```

locm_ppv <- localmoran(carte$Cambriolage_centered, PPV5.w)
head(locm_ppv)

```

4.1.2.2 Autocorrelation Spatiale locale (LISA)

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
1	-0.09711941	-0.011221677	0.20397295	-0.1901934	0.8491576
2	0.12536339	-0.002722010	0.04990244	0.5733750	0.5663908
3	-0.02940138	-0.001400731	0.02571354	-0.1746173	0.8613804
4	-0.18550082	-0.001400731	0.02571354	-1.1480823	0.2509346
5	-1.07722747	-0.023686852	0.42512082	-1.6158279	0.1061315
6	0.05967118	-0.009403665	0.17124178	0.1669226	0.8674310


```
summary(locm_ppv)
```

Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
Min. : -1.83029	Min. : -7.876e-02	Min. : 0.0000463	Min. : -2.6237	Min. : 0.0001157
1st Qu.: -0.15024	1st Qu.: -1.346e-02	1st Qu.: 0.0275376	1st Qu.: -0.7491	1st Qu.: 0.1955577
Median : 0.05847	Median : -4.433e-03	Median : 0.0811361	Median : 0.3465	Median : 0.3721853
Mean : 0.12326	Mean : -1.053e-02	Mean : 0.1875115	Mean : 0.2163	Mean : 0.4111885
3rd Qu.: 0.22596	3rd Qu.: -1.500e-03	3rd Qu.: 0.2441476	3rd Qu.: 1.0641	3rd Qu.: 0.6287198
Max. : 3.73213	Max. : -2.520e-06	Max. : 1.3338876	Max. : 3.8550	Max. : 0.9766180

```
carte$ppvW_cambriolage <- lag.listw(PPV5.w, carte$Cambriolage_centered)
#create a new variable for quadrants
base$quad_sig_ppv <- NA

##HH
carte@data[(carte$Cambriolage_centered >= 0 & carte$ppvW_cambriolage >= 0) &
  (locm_ppv[,5] <= 0.05), "quad_sig_ppv"] <- 1.0

##LL
carte@data[(carte$Cambriolage_centered <= 0 & carte$ppvW_cambriolage <= 0) &
  (locm_ppv[,5] <= 0.05), "quad_sig_ppv"] <- 2.0

##HL
carte@data[(carte$Cambriolage_centered >= 0 & carte$ppvW_cambriolage <= 0) &
  (locm_ppv[,5] <= 0.05), "quad_sig_ppv"] <- 3.0

##LH
carte@data[(carte$Cambriolage_centered <= 0 & carte$ppvW_cambriolage >= 0) &
  (locm_ppv[,5] <= 0.05), "quad_sig_ppv"] <- 4.0

#pas significatifs
carte@data[(locm_ppv[,5] > 0.05), "quad_sig_ppv"] <- 5.0

table(carte$quad_sig_ppv)
```

4.1.2.3 Maps de Lisa

```
1 4 5
5 2 89


labels <- c("high-High", "low-Low", "High-Low", "Low-High", "Not Signif.")

# need for the map
breaks <- seq(1, 5, 1)

carte$np_1 <- findInterval(carte$quad_sig_ppv, breaks)

col.map <- c("red", "blue", "lightpink", "skyblue2", "yellow")
plot(carte, col = col.map[carte$np_1])
mtext("Local Moran's I Significatif or Not", cex = 1.5, side = 3, line = 1)
legend("topleft", legend = labels, col=c("red", "blue", "lightpink", "skyblue2", "yellow"),
  lty=1:2, cex=0.8)
```

Local Moran's I Significatif or Not



4.1.3 L'inverse de la distance

```
MoranTest_dist.w1 <- moran.test(carte$Cambriolage_centered, dist.w1, randomisation = FALSE,
                                alternative = "greater")
```

```
MoranTest_dist.w1
```

4.1.3.1 Indice de Moran

Moran I test under normality

```
data: carte$Cambriolage_centered
weights: dist.w1
```

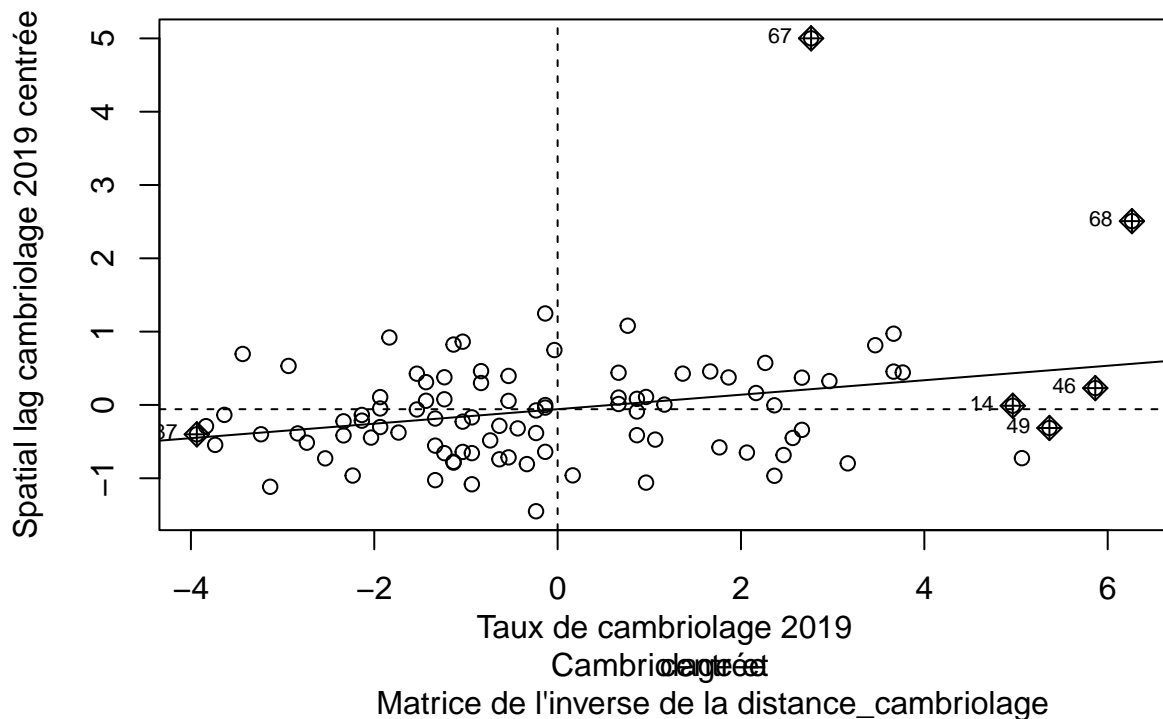
Moran I statistic standard deviate = 4.3791, p-value = 5.96e-06

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.0987729599	-0.0105263158	0.0006229771

```
moran.plot(x = carte$Cambriolage_centered, listw = dist.w1, xlab = "Taux de cambriolage 2019
centrée", ylab = "Spatial lag cambriolage 2019 centrée", sub = "Cambriolage et
Matrice de l'inverse de la distance_cambriolage", labels = as.character(row.names(carte)))
```



- Interprétation :

Moran I statistic standard deviate = 4 > 0 ==> Possible Positive spatial autocorrelation p-value = 6e-06 < 0.05 ==> On rejette H0 (Spatial Autocorrelation)

```
locm_dist <- localmoran(carte$Cambrilage_centered, dist.w1)
head(locm_dist)
```

4.1.3.2 Autocorrélation Spatial Local (LISA)

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
1	-0.002251716	-0.011221677	0.015063191	0.07308564	0.94173797
2	0.001073872	-0.002722010	0.001712024	0.09173979	0.92690478
3	-0.073446969	-0.001400731	0.002213230	-1.53143325	0.12566235
4	-0.047639575	-0.001400731	0.001324925	-1.27031484	0.20397250
5	-0.455431872	-0.023686852	0.045847198	-2.01637329	0.04376096
6	0.067152881	-0.009403665	0.010304398	0.75417307	0.45074530

```
summary(locm_dist)
```

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
Min.	:-0.70106	Min. :-7.876e-02	Min. :0.0000071	Min. :-3.0021	Min. :0.0003798
1st Qu.:	-0.03402	1st Qu.:-1.346e-02	1st Qu.:0.0017767	1st Qu.: -1.1507	1st Qu.:0.0550597
Median :	0.03973	Median :-4.433e-03	Median :0.0076849	Median : 0.7165	Median :0.1690172
Mean :	0.09877	Mean :-1.053e-02	Mean :0.0541316	Mean : 0.4017	Mean :0.2828768
3rd Qu.:	0.16853	3rd Qu.: -1.500e-03	3rd Qu.:0.0330086	3rd Qu.: 1.5842	3rd Qu.:0.4168653
Max. :	2.99508	Max. :-2.520e-06	Max. :2.2603645	Max. : 3.5537	Max. :0.9915076

```

carte$distw1_cambriolage <- lag.listw(dist.w1, carte$Cambriolage_centered)
#create a new variable for quadrants
carte$quad_sig_dist <- NA

##HH
carte@data[(carte$Cambriolage_centered >= 0 & carte$distw1_cambriolage >= 0) &
  (locm_dist[,5] <= 0.05), "quad_sig_dist"] <- 1.0

##LL
carte@data[(carte$Cambriolage_centered <= 0 & carte$distw1_cambriolage <= 0) &
  (locm_dist[,5] <= 0.05), "quad_sig_dist"] <- 2.0

##HL
carte@data[(carte$Cambriolage_centered >= 0 & carte$distw1_cambriolage <= 0) &
  (locm_dist[,5] <= 0.05), "quad_sig_dist"] <- 3.0

##LH
carte@data[(carte$Cambriolage_centered <= 0 & carte$distw1_cambriolage >= 0) &
  (locm_dist[,5] <= 0.05), "quad_sig_dist"] <- 4.0

#pas locm_dist
carte@data[(locm_dist[,5] > 0.05), "quad_sig_dist"] <- 5.0

table(carte$quad_sig_dist)

```

4.1.3.3 Maps de Lisa

```

1 2 3 4 5
4 11 4 5 72

labels <- c("high-High", "low-Low", "High-Low", "Low-High", "Not Signif.")

# need for the map


breaks <- seq(1, 5, 1)

carte$np_2 <- findInterval(carte$quad_sig_dist, breaks)

col.map <- c("red", "blue", "lightpink", "skyblue2", "yellow")
plot(carte, col = col.map[carte$np_2])
mtext("Local Moran's I Significatif or Not", cex = 1.5, side = 3, line = 1)
legend("topleft", legend = labels, col=c("red", "blue", "lightpink", "skyblue2", "yellow"),
  lty=1:2, cex=0.8)

```

Local Moran's I Significatif or Not



- Résumé des matrices
1. Matrice de contiguïté : No Spatial Autocorrelation ;
 2. Matrice des plus proche voisin : Spatial Autocorrelation ;
 3. Matrice de l'inverse de la distance : Spatial Autocorrelation

5 Estimation des modèles via la stratégie de test Top-Down

5.1 Estimation des modèles

Pour la suite, on utilisera la matrice de l'inverse de la distance. Elle contient le plus d'indice significatif parmi les trois. Une comparaison sera faite avec les résultats avec la matrice de contiguïté pour observer les éventuelles différences.

```
library(spatialreg)
```

Warning: le package 'spatialreg' a été compilé avec la version R 4.2.2

Le chargement a nécessité le package : Matrix

Attachement du package : 'spatialreg'

Les objets suivants sont masqués depuis 'package:spdep':

```
get.ClusterOption, get.coresOption, get.mcOption, get.VerboseOption, get.ZeroPolicyOption, set.Clus  
set.ZeroPolicyOption
```

```
formule <- Cambriolage ~ Taux_chomage_2019 + Policier_Gendarme + Part_Maison + Personne_Seule
```

5.1.1 Modèle OLS

```
Criminality_OLS <- lm(formula = formule, data = carte)
```

5.1.2 Modèle SLX

```
carte$Taux_chomage_2019_M <- carte$Taux_chomage_2019 - mean(carte$Taux_chomage_2019)
carte$W_Taux_chomage_2019_M <- lag.listw(dist.w1, carte$Taux_chomage_2019_M)

carte$Policier_Gendarme_M <- carte$Policier_Gendarme - mean(carte$Policier_Gendarme)
carte$W_Policier_Gendarme_M <- lag.listw(dist.w1, carte$Policier_Gendarme_M)

carte$Part_Maison_M <- carte$Part_Maison - mean(carte$Part_Maison)
carte$W_Part_Maison_M <- lag.listw(dist.w1, carte$Part_Maison_M)

carte$Personne_Seule_M <- carte$Personne_Seule - mean(carte$Personne_Seule)
carte$W_Personne_Seule_M <- lag.listw(dist.w1, carte$Personne_Seule_M)

Criminality_SLX <- lm(Cambriolage_centered ~ Taux_chomage_2019_M + Policier_Gendarme_M +
  Part_Maison_M + Personne_Seule_M + W_Taux_chomage_2019_M +
  W_Policier_Gendarme_M + W_Part_Maison_M + W_Personne_Seule_M, data = carte)
```

5.1.3 Modèle SAR

```
Criminality_SAR <- lagsarlm(formula = formule, listw = dist.w1, data = carte)
```

5.1.4 Modèle SEM

```
Criminality_SEM = errorsarlm(formula = formule, listw=dist.w1, data=carte)
```

5.1.5 Modèle SDM

```
Criminality_SDM <- lagsarlm(formula = formule, listw = dist.w1, type = "mixed", data = carte)
```

5.2 Strategy of test Top Down approach LeSage & Pace (2009)

- SDM VS SAR : On test

$H_0 : \delta = 0$, If H_0 rejected = SDM

```
sdm_vs_sar <- LR.Sarlm(Criminality_SDM,Criminality_SAR)
print(sdm_vs_sar)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 2.6416, df = 4, p-value = 0.6195

sample estimates:

Log likelihood of Criminality_SDM	Log likelihood of Criminality_SAR
-190.3348	-191.6556

On a $p - value = 0.6195 > 0.05 \Rightarrow$ On ne rejette pas H_0 donc $\delta = 0$

- sar_vs_ols

```
sar_vs_ols <- LR.Sarlm(Criminality_SAR,Criminality_OLS)
print(sar_vs_ols)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 0.70297, df = 1, p-value = 0.4018

sample estimates:

Log likelihood of Criminality_SAR	Log likelihood of Criminality_OLS
-191.6556	-192.0071

$p - value = 0.4018$, on ne rejette pas nulle H_0 on retient donc le Modele OLS

- SDM vs SLX

$H_0 : \rho=0$, $\theta \neq 0$ et $\theta + \rho*\beta \neq 0$ unconstrained model : SDM constrained model : SLX If H_0 reject : SDM

```
sdm_vs_slx <- LR.Sarlm(Criminality_SDM, Criminality_SLX)
print(sdm_vs_slx)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 0.024426, df = 1, p-value = 0.8758

sample estimates:

Log likelihood of Criminality_SDM	Log likelihood of Criminality_SLX
-190.3348	-190.3470

$p - value = 0.8759 > 5\%$, on accepte H_0

- slx_vs_ols

```
slx_vs_ols<-LR.Sarlm(Criminality_SLX,Criminality_OLS)
print(slx_vs_ols)
```

Likelihood ratio for spatial linear models

data:

Likelihood ratio = 3.3201, df = 4, p-value = 0.5057

sample estimates:

Log likelihood of Criminality_SLX	Log likelihood of Criminality_OLS
-190.3470	-192.0071

$p - value = 0.5058 > 5\% \Rightarrow p = 0 \Rightarrow$ Modele OLS

- sdm_vs_sem

```
sdm_vs_sem <-LR.Sarlm(Criminality_SDM,Criminality_SEM)
print(sdm_vs_sem)
```

Likelihood ratio for spatial linear models

```
data:
Likelihood ratio = 3.3142, df = 4, p-value = 0.5067
sample estimates:
Log likelihood of Criminality_SDM Log likelihood of Criminality_SEM
-190.3348 -191.9919
```

$p - value = 0.5067 > 0.05$, on accepte H_0

```
sem_vs_ols<-LR.Sarlm(Criminality_SEM,Criminality_OLS)
print(sem_vs_ols)
```

Likelihood ratio for spatial linear models

```
data:
Likelihood ratio = 0.030321, df = 1, p-value = 0.8618
sample estimates:
Log likelihood of Criminality_SEM Log likelihood of Criminality_OLS
-191.9919 -192.0071
```

$p - value = 0.8618$, on choisit donc le modèle OLS

5.3 Visualisation du modèle

```
summary(Criminality_OLS)
```

Call:

```
lm(formula = formule, data = carte)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.1055	-1.0781	-0.2373	1.1486	5.6935

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.025975	2.719695	4.422	2.7e-05 ***
Taux_chomage_2019	0.470191	0.119143	3.946	0.000156 ***
Policier_Gendarme	-0.184602	0.177755	-1.039	0.301780
Part_Maison	-0.071505	0.011779	-6.070	2.9e-08 ***
Personne_Seule	-0.013267	0.006621	-2.004	0.048071 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.837 on 91 degrees of freedom

Multiple R-squared: 0.3904, Adjusted R-squared: 0.3636

F-statistic: 14.57 on 4 and 91 DF, p-value: 3.109e-09

5.4 Interprétation du modèle

5.5 Test sur le modèle

- Si le taux de chômage augmente de 1 point de pourcentage, le taux de cambriolage pour 1000 habitants augmente de 0.47 point de pourcentage ;
- Nombre de policier augmente d'une unité, le taux de cambriolage pour 1000 habitants diminue de 0.18 point de pourcentage ;

- Une augmentation de la part maison entraînant une très petite diminution du taux de cambriolage pour 1000 habitants ;
- Une relation négative entre le nombre de personne seule et le taux de cambriolage pour 1000 habitants, cependant avec un coefficient très petit.

5.5.1 Test de Moran

```
Moran_Res <- lm.morantest(Criminality_OLS, listw = dist.w1, alternative = "two.sided")
Moran_Res
```

Global Moran I for regression residuals

data:

model: lm(formula = formule, data = carte)

weights: dist.w1

Moran I statistic standard deviate = 0.70976, p-value = 0.4779

alternative hypothesis: two.sided

sample estimates:

Observed Moran I	Expectation	Variance
0.0054479339	-0.0117653576	0.0005881748

5.6 Test avec une matrice des cinq plus proche voisins

```
Criminality_SAR_ppv <- lagsarlm(formula = formule, listw = PPV5.w, data = carte)
summary(Criminality_SAR_ppv)
```

Call: lagsarlm(formula = formule, data = carte, listw = PPV5.w)

Residuals:

Min	1Q	Median	3Q	Max
-4.99161	-1.10979	-0.14664	1.03475	5.43651

Type: lag

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	11.5971273	2.7851220	4.1640	3.128e-05
Taux_chomage_2019	0.4542496	0.1175188	3.8653	0.0001109
Policier_Gendarme	-0.1864471	0.1728009	-1.0790	0.2806009
Part_Maison	-0.0702286	0.0116653	-6.0203	1.741e-09
Personne_Seule	-0.0133422	0.0064552	-2.0669	0.0387431

Rho: 0.087811, LR test value: 0.41772, p-value: 0.51807

Asymptotic standard error: 0.12457

z-value: 0.70491, p-value: 0.48087

Wald statistic: 0.4969, p-value: 0.48087

Log likelihood: -191.7982 for lag model

ML residual variance (sigma squared): 3.1794, (sigma: 1.7831)

Number of observations: 96

Number of parameters estimated: 7

AIC: 397.6, (AIC for lm: 396.01)

LM test for residual autocorrelation
test value: 0.05437, p-value: 0.81563

On remarque que la significativité des mêmes variables explicatives que pour le modèle OLS avec la matrice de l'inverse de la distance. Cela témoigne donc de la robustesse de notre modèle.

Conclusion

Dans ce projet, nous avons donc expliqué le taux de cambriolage en France pour 1000 habitants. Tout d'abord, nous avons fait une statistique descriptive de nos données. Nous avons construit 3 matrices de poids différentes. On a choisi au final de conserver la matrice de l'inverse de la distance car c'est la plus significative sur les indices (Indice de Moran et LISA). Ensuite, nous avons effectué les modèles économétriques spatiaux, on a donc retenu le modèle de régression linéaire simple. La variable qui explique le mieux le taux de cambriolage en France pour 1000 habitants est le taux de chômage. On conclut donc qu'un département avec un taux de chômage important a d'avantage de cambriolage qu'un département avec un taux de chômage plus faible.